

论文叙事大纲

1. 研究背景与优化瓶颈

城市交通数字孪生是评估智慧交通策略与基础设施方案的重要支撑，其可信度取决于底层微观仿真（如 SUMO）能否复现真实交通的宏观统计与微观行为。微观行为参数（跟驰、换道等十维控制量）的联合标定，在工程上表现为**单次评估即需一次完整仿真**的高开销黑盒优化：参数维度不低、目标景观非凸且随场景剧烈变化，而 TraCI 闭环仿真的时间成本使「大量试算」在实践上难以承受。

既有路线大致分为两类，均在「昂贵仿真」约束下暴露短板。**全局启发式搜索**（如遗传算法 GA）需要维持种群并反复调用仿真，若在可接受的 wall-clock 内停止，往往尚未充分探索参数空间；**局部梯度类方法**（如 SPSSA）在百次量级的预算内难以穿越多峰景观，且梯度估计本身即消耗双倍仿真。于是，高维参数搜索与昂贵仿真成本之间形成结构性矛盾：既要在有限预算内尽可能全局地「看准」参数，又不能让每一次仿真都花在盲目试探上。

2. 现有方法的局限与核心假设

方法局限。 将交通标定完全交给与领域无关的通用黑盒优化器，常见做法是把高维时空轨迹压缩为单一标量误差或直接拟合「参数→误差」而缺乏可解释结构。此类表述虽便于优化，却未利用交通流在速度分布、加减速强度、停车占比等统计量上的**稳定可迁移规律**，寻优过程容易在参数空间中漫无目的地游走，样本效率低。

核心假设。 在单次仿真极其昂贵的约束下，提升样本效率的关键在于注入**交通领域先验**：用具有物理含义的低维表征替代「原始轨迹逐点比对」式的目标构造，使参数—响应关系更平滑、更可学习；再在此表征上，用**少量精心设计的真仿真**训练代理模型，并以**序贯采集**把剩余预算集中在最有希望的区域，而不是一次性耗尽预算于均匀或随机试探。

3. 方法论：BF-SAC 代理辅助标定框架

基于上述假设，本文提出面向微观交通仿真标定的 **BF-SAC**（Behavioral Fingerprint Surrogate-Assisted Calibration，行为指纹代理辅助标定）框架。与旧版叙事不同，当前实现**不包含**差分进化（DE）抛光阶段，也**不以**论文第 4 章「综合保真度 S_{comp} 」作为优化目标；标定与对比统一最小化八维行为指纹加权误差 J_b ，在固定 **101 次 SUMO** 预算下完成（60 次拉丁超立方 LHS 初始设计 + 41 次序贯下置信界 LCB 加占点）。

3.1 领域知识特征化（降维表征）

放弃在优化内环中直接对齐原始轨迹点位的做法，从真实数据与仿真输出中提取涵盖速度水平与分位、加减速强度、停车占比等的**八维行为指纹**，并采用场景相关的权重构成 J_b 。该步骤将高维时空数据映射为低维、可解释的误差向量，使不同参数组合的差异集中在交通行为统计上，从而**平滑并结构化**黑盒目标，为后续代理学习提供稳定监督信号。

框架第二层将「昂贵真仿真」与「廉价代理推断」解耦：

- 1. **初始设计：** 以 LHS 在十维参数边界内生成 60 个空间填充样本，每次样本触发一次 SUMO 评估，并据此训练随机森林 (RF) 代理，拟合「参数 $\rightarrow J_b$ 」映射。六场景 RF 拟合 R^2 均不低于约 0.94，说明在有限样本下代理已具备可用精度。
- 2. **序贯加点：** 在剩余 41 次预算内，每轮重训 RF，于信赖域与全局候选池中按 **LCB (下置信界)** 准则选点，再调用真仿真验证并更新样本库。该机制替代了对代理曲面做 DE 全局搜索的旧流程，更贴合「预算刚性、逐次决策」的昂贵优化设定。
- 3. **场景自适应：** 参数边界与指纹权重可按场景 (如长春、西安、RML) 调整，避免用单一先验强加于异构交通环境。

叙事要点 (写作时可强调)： BF-SAC 不是「用代理完全取代仿真」，而是「用代理决定下一次仿真花在哪里」；101 次真仿真全部计入预算，保证结论可复现、可与其他方法在 **相同仿真次数快照** 下公平比较。

4. 实验验证与主要贡献

4.1 实验设计

- **数据与场景：** 基于 SIND 与 UTE 真实轨迹，构建 **六个异构场景**——天津、长春、西安三个信号交叉口，以及 YTDJ 合流区、RML 交织区、XAM-N6 高速合流区。
- **标定协议：** 每场景 BF-SAC 总预算 101 次 SUMO，`calibration_mode = sequential_lcb`。
- **对比协议：** 公平预算 101——在累计仿真首次达到 101 次时记录各方法的最优 J_b (`error_at_budget`)；另设消融 **No-RF** (无代理、LHS 满预算)、**No-LHS** (无 LHS、随机 101 点)，基线 **GA** (约 765 次仿真)、**SPSA** (约 301 次仿真)，用于检验组件贡献与经典黑盒法的样本效率。

4.2 标定性能 (指纹误差, 非旧版「80 分保真度」)

六场景 BF-SAC 终态 J_b 跨度约 **0.044 (XAM-N6) $\sim$ 0.477 (RML)**，反映场景难度差异而非单一分数可概括。快速路低拥堵场景更易标定；交织区 RML 误差最高，提示复杂几何与流态对微观参数辨识提出更高要求。序贯 LCB 在 XAM-N6、西安等场景相对纯 DoE 仍有改进，说明在初始 LHS 之后仍有利用代理指导采样的价值。

4.3 算法对比与消融 (101 次预算快照, 六场景平均)

指标	BF-SAC	GA	No-RF	No-LHS	SPSA
平均 J_b @101	0.212	0.228	0.246	0.256	0.313
相对 BF-SAC 误差增幅	—	+7.2%	+15.6%	+20.5%	+47.4%
典型总仿真次数	101	765	101	101	301

- **同预算最优：** 在 101 次仿真快照下，BF-SAC 六场景平均 J_b 最低；GA 若允许继续运行至约 **7.6 倍** 仿真量（765 次），部分场景终态可进一步下降，但在第 101 次快照上仍平均落后约 7.2%。
- **样本效率：** 相对 GA/SPSA，BF-SAC 的优势体现在「**百次仿真内**达到更低指纹误差」，而非宣称固定的「12 倍 / 5 倍」加速比（该表述来自旧实验设定，应删除）。
- **消融含义：** 去掉 LHS (+20.5%) 劣于去掉 RF 代理 (+15.6%)，说明**空间填充实验设计**是预算内的第一性因素；序贯 LCB 在平均意义上提供额外增益，尤其在初始设计已较充分时表现为「精炼」而非「替代」LHS。
- **场景异质性：** 不存在单一方法在六场景全面占优（如 XAM-N6、西安上纯 LHS 与 BF-SAC 接近），但 BF-SAC 在**跨场景平均**意义下最稳健，适合作为默认可复现标定管线。

4.4 总体贡献

1. **问题刻画：** 将微观交通仿真标定明确为「昂贵仿真约束下的十维黑盒优化」，并以可复现的 J_b 与 101 次预算协议固定评价口径。
2. **方法贡献：** 提出 BF-SAC——八维行为指纹降维 + RF 代理 + LHS 初始设计 + 序贯 LCB，形成与 SUMO–TraCI 闭环对接的开源实现。
3. **实证贡献：** 在六类真实异构场景上完成标定与公平对比，证明领域特征化与代理序贯耦合可在**百次仿真量级**内优于 GA/SPSA 的预算快照表现，并通过消融量化 LHS 与代理各自的贡献。
4. **范式意义：** 表明复杂交通系统的黑盒标定中，「**领域特异性表征**」与「**机器学习代理 + 序贯决策**」的耦合，是兼顾计算可负担性与优化质量的可行路径；评价应基于**指纹误差与固定仿真预算**，而非脱离优化目标的事后综合评分。

5. 图表与材料索引

图/表	文件	叙事功能
图 1	bfsac_calibration_convergence.png	六场景 BF-SAC 收敛，论证预算内下降与序贯段价值
图 2	method_comparison_panel.png	六场景平均收敛 + 预算柱图 + 消融 proxy
图 3	multiscene_method_convergence.png	分场景方法对比，论证异质性
数据	comparison_summary.csv、ablation_summary.csv	表 2 / 消融数值来源

详细解读见 `EXPERIMENT.md`。