

实验与结果分析

1. 实验设置

1.1 场景与数据

实验覆盖六个异构交通场景：SIND 信号交叉口（天津、长春、西安）与 UTE 城市快速路（YTDJ 合流区、RML 交织区、XAM-N6 高速合流区）。各场景由真实轨迹提取 8 维行为指纹作为标定目标，在 SUMO 数字孪生中通过 TraCI 动态改写跟驰与换道参数，每次参数评估对应一次完整仿真。

1.2 目标函数与公平预算

标定与对比统一最小化加权指纹误差 J_b ：

$$J_b(\theta_b) = \sum_{k=1}^8 w_k \cdot \min \left(\frac{|f_k^{sim} - f_k^{real}|}{\max(|f_k^{real}|, \epsilon)}, 3 \right)$$

对比实验采用 **公平预算 100 次 SUMO**。记 `error_at_budget` 为累计仿真次数首次达到 100 时迄今为止的最小 J_b 。所有方法总仿真次数均为 100。

实验分两层（`run_comparison.py --mode`）：

- 1. **主对比（main）**：BF-SAC-RF / BF-SAC-MLP（`n_init=40`，序贯 LCB κ 从 **2.0 线性退火至 0.5**）对四种异构基线 SPSA / GA / CMA-ES / TPE。
- 2. **样本效率消融（sweep）**：BF-SAC-RF 与 BF-SAC-MLP 在 `n_init ∈ {20, 40, 60, 80, 100}` 下扫描（总预算恒为 100；`n_init=100` 为纯 LHS，共用 100 点嵌套 LHS 设计）。

1.3 主对比方法（ICTAI）

方法	机制族	含义	仿真次数
BF-SAC-RF	代理 / 序贯模型优化	40 LHS + 60 序贯 LCB（RF）	100
BF-SAC-MLP	代理 / 序贯模型优化	40 LHS + 60 序贯 LCB（MLP）	100
SPSA	局部梯度估计	同步扰动随机逼近	100
GA	进化 / 种群	种群遗传算法（10×10 波）	100
CMA-ES	演化策略	协方差自适应演化策略	100
TPE	贝叶斯密度估计	树结构 Parzen 估计（Optuna）	100

异构基线的选取。 四个基线刻意覆盖不同机制族，以检验 BF-SAC 是否在“别的范式”面前都站得住：SPSA 代表局部梯度估计，GA 代表种群进化，CMA-ES 是无导数连续优化的事实标准（演化策略），TPE 则是 AutoML 领域最常用的模型类基线。需要说明的是，TPE 虽也“学习”，但建模的是好/坏配置的密度比

$p(x | y)$ ，与 BF-SAC 的回归代理 $p(y | x)$ +采集函数是不同范式；而高斯过程贝叶斯优化与 BF-SAC 同属代理族，不计入异构基线。


两种代理，同一套机制。 BF-SAC 的核心是“行为指纹降维 + LHS 初始设计 + 序贯 LCB 加点”，代理模型只是其中可替换的一环。序贯 LCB 为 RF 与 MLP 共用，二者的区别仅在代理本身，故方法名以代理标识即可（BF-SAC-RF / BF-SAC-MLP），无需再缀“序贯 LCB”。RF 训练轻量、对小样本稳健；MLP 为 10 成员集成，容量更高、在难拟合的响应面上更细。两者并存正是为了说明框架对代理的选择并不敏感。主对比固定 `n_init=40`，样本量的影响由 `--mode sweep` 扫描 `n_init ∈ {20,40,60,80,100}` 单独报告。

多 seed 统计协议。 优化重复实验使用 `--seeds`（各方法共用同一 seed 列表；BF-SAC 的 LHS/序贯/代理随机源均随 `run_seed` 变化）；cache 为 `*_b100_s{seed}.json`（seed=42 兼容无后缀）。聚合输出 `comparison_per_run.csv`、`comparison_multiseed_stats.csv`（均值±seed 内 std）；作图见 `multiseed_global_bars.png`、`multiseed_scene_heatmap.png`。正式 5 次重复计划 seed：42, 101, 202, 303, 404。

2. BF-SAC 标定结果

2.1 六场景收敛与终态误差

图 1 给出六场景标定过程的运行最优 J_b 收敛曲线，RF 与 MLP 两种代理并列、各为 5 seed 的均值线加 ±1 std 半透明带：前 40 次为 LHS 初始设计，竖虚线之后为序贯 LCB 加点（ $\kappa 2 \rightarrow 0.5$ 退火，总预算 100）。初始阶段误差随样本累积快速下降，序贯阶段在多数场景仍能带来可见改进。两条曲线大体重合，仅在 RML、西安等较难场景上 MLP 收得更低、带更窄。



标定终态指纹误差（`calibration_summary.csv`）如表 1 所示。快速路场景 XAM-N6 最低（ $J_b = 0.068$ ），交织区 RML 最高（ $J_b = 0.470$ ），说明场景几何与交通流态差异直接决定标定难度。交叉口场景内部也不齐整：天津、长春较易（0.141、0.159），西安却高达 0.427——后者饱和度高、相位切换频繁，指纹中停车占比与加减速分位的目标更难同时满足，是误差最高的交叉口。

表 1 六场景 BF-SAC 标定终态行为指纹误差 J_b

场景	类型	J_b	$RF R^2$	RF RMSE
XAM-N6	高速合流	0.068	0.964	0.021
Xian	信号交叉口	0.427	0.911	0.018
Tianjin	信号交叉口	0.141	0.971	0.057
YTDJ	快速路合流	0.244	0.981	0.025
Changchun	信号交叉口	0.159	0.987	0.022
RML	快速路交织	0.470	0.976	0.037

仅 40 个 LHS 样本即可让 RF 训练 R^2 稳定在 0.94 以上，说明八维指纹已把原本崎岖的参数—误差关系压平到代理可学的程度。正是这一点让随后的 LCB 选点有据可依，而非在噪声上空转。竖虚线之后多数场景的运行最优仍在下探，XAM-N6、天津尤为明显，表明序贯阶段并非对初始设计的简单重复，而是在代理指引下持续向更优区域逼近。

2.2 标定参数的场景分异（简述）

标定得到的微观参数呈现清晰的环境梯度：XAM-N6 的 `speedFactor` 达 1.17、`tau` 低至 0.5 s，符合高速合流下较高的速度离散与较短跟车时距；RML 的 `tau`≈2.32 s、`minGap` 较大，体现交织区保守跟驰；YTDJ 的 `accel` 上限附近（约 3.5 m/s²）与合流加减速频繁相对应。参数分异说明统一框架并未强加“一套参数走天下”，而是随场景自动收敛到可解释的局部最优。




RF 与 MLP 的逐场景对比不在此展开：两者在相同预算、相同 LHS 下并存，完整的 5 seed 结果统一放在第 3 节（表 3 与 §3.4），以免单次标定与多 seed 对比口径混淆。

3. 方法对比与消融实验

3.1 组合图：收敛、预算快照与评分 proxy

图 2 上方为六种方法在六个场景上的平均收敛曲线、下方为 @100 预算快照柱图与评分 proxy。分场景细粒度曲线见图 3。

6 场景平均收敛对比

图 2 方法对比 (x 轴止于 100; 六场景算术平均; 阴影为 5 seed 间 ± 1 std)

3.2 公平预算 100 对比 (六场景平均)

表 2 六场景平均对比 (5 seed 均值, error_at_budget @100)

方法	平均 J_b	评分 proxy	相对 BF-SAC-RF 误差增幅	100 次仿真
BF-SAC-RF	0.241	89.2	—	100
BF-SAC-MLP	0.240	89.2	-0.1%	100
TPE	0.257	88.4	+6.7%	100
遗传算法 (GA)	0.276	87.6	+14.7%	100
CMA-ES	0.280	87.4	+16.3%	100
SPSA	0.383	82.7	+59.3%	100

在相同 100 次预算、5 seed 重复下，BF-SAC (RF/MLP, 0.240–0.241) 低于全部四个异构基线：TPE 0.257、GA 0.276、CMA-ES 0.280、SPSA 0.383。这一结果跨越了梯度估计、种群进化、演化策略、贝叶斯密度四种不同范式，说明优势来自方法本身，而非与某一类算法的偶然契合。误差棒与分场景热力图见 [multiseed_globalBars.png](#)、[multiseed_scene_heatmap.png](#)。

基线的次序本身就有信息量。**TPE 是最强对手**——它同为模型类方法，靠密度比快速锁定有希望的区域，却仍落后约 7%，差距正落在 BF-SAC 的两处优势上：领域指纹把目标压得更平滑，回归代理 + LCB 比逐维密度估计更善于利用参数间的耦合。**CMA-ES 在百次预算内偏弱** (0.280)，印证了演化策略“样本饥

渴”的本性：10 维下种群约 10、仅够跑十代，协方差还没自适应到位预算就用尽了。**SPSA 垫底**且方差大，其总平均被长春（0.603）这类失稳结果拖高。可见 BF-SAC 的领先不靠某一两个场景的极端值，而是在六个场景上一致靠前。

3.3 分场景要点

表 3 各场景 5 seed 均值 J_b （越小越好，加粗为最优；括号内为 seed 内 std）

场景	BF-SAC-RF	BF-SAC-MLP	TPE	GA	CMA-ES	SPSA
XAM-N6	0.044 (0.008)	0.049 (0.011)	0.047 (0.008)	0.045 (0.006)	0.062 (0.013)	0.162 (0.114)
Xian	0.430 (0.005)	0.425 (0.005)	0.426 (0.013)	0.440 (0.020)	0.435 (0.008)	0.440 (0.003)
Tianjin	0.146 (0.011)	0.164 (0.020)	0.165 (0.010)	0.170 (0.013)	0.170 (0.016)	0.192 (0.054)
YTDJ	0.223 (0.014)	0.218 (0.003)	0.284 (0.067)	0.313 (0.040)	0.280 (0.058)	0.365 (0.092)
Changchun	0.168 (0.016)	0.180 (0.029)	0.167 (0.013)	0.225 (0.050)	0.293 (0.109)	0.603 (0.097)
RML	0.434 (0.022)	0.408 (0.007)	0.452 (0.008)	0.464 (0.048)	0.440 (0.017)	0.540 (0.129)

BF-SAC（RF 或 MLP）在六场景中**五个取得最优**，唯一例外是长春——TPE 以 0.167 对 BF-SAC-RF 0.168 险胜，差距远在彼此 std 之内，实为平局。换言之，没有任何异构基线能在哪个场景上明显压过 BF-SAC。

分场景的差距大小，则由目标景观的形态决定。西安是典型的“平底”场景，六种方法的 J_b 都压在 0.43 附近、相差不足 0.02——误差主要来自指纹与参数空间的固有失配，留给优化的余地本就有限，连 SPSA 也不落下风。长春、RML 等崎岖场景则把方法间差距拉开：SPSA 两点梯度易陷局部陷阱，CMA-ES 在百次预算内来不及自适应（长春 0.293、方差大），而代理凭借对全局曲面的平滑拟合稳定胜出。XAM-N6 误差最低（RF 0.044），GA、TPE 几乎追平（0.045、0.047），说明当最优区域宽阔易达时，各路方法殊途同归。可见 BF-SAC 的价值，集中在那些中等崎岖、需要“看准方向再落子”的场景。

3.4 N_init 样本效率消融（sweep）




图 4 RF/MLP 在 $n_{init} \in \{20, 40, 60, 80, 100\}$ 下的终态 J_b (总预算 100; 各点 5 seed 均值, 半透明带 ± 1 std; $n_{init}=100$ 为纯 LHS)

五个 n_{init} 档位补齐到 5 seed 后, 消融给出了比主对比更干净的因果证据。最稳健的一条规律是: 总预算锁定为 100 时, 纯 LHS ($n_{init}=100$ 、无序贯) 在几乎所有场景上都是最差或接近最差的配置——长春由 0.168 抬到 0.236, 天津由 0.146 抬到 0.182, RML 的 MLP 由 0.399 抬到 0.505。这直接表明, 把后半程预算交给代理引导的 LCB 选点, 远比继续做空间填充划算; 序贯机制的增益是真实的, 而非初始设计的副产品。其次, 最优 n_{init} 普遍落在偏小的 20–40 区间, 意味着代理只需少量样本即可“上手”, 此后每一次仿真都应尽量用于定向加点, 而不是扩充初始库。 $n_{init}=40$ 恰处“代理已可靠、又给序贯留足 60 步”的平衡点, 这也是主对比取此值的原因。

代理怎么选, 由场景的拟合难度决定。 把六场景按可达误差排序, 规律相当清晰。三个“易拟合”场景——XAM-N6 ($J_b \approx 0.044$)、天津 (0.146)、长春 (0.168), RF 训练 R^2 已在 0.96–0.99——RF 与 MLP 打平甚至 RF 略优, MLP 的额外容量无处发力。三个“难拟合”场景里, MLP 的优势随拟合难度上升而显现: 西安响应面最崎岖, RF 仅能拟合到 $R^2=0.911$, 换 MLP 升到 0.952; RML 由 0.976 升到 0.997, 终态 J_b 也从 0.434 明显降到 0.408 (约 6%)。换言之, MLP 的高容量只在 RF 力有不逮、响应面复杂时才兑现为更低误差。方差视角给出同一结论: RF 轻量但对初始设计敏感 (YTDJ $n_{init}=20$ 时 std 达 0.079), MLP 以集成平均换取一致 (同档 0.013)。因此把 RF 当轻量默认、MLP 留给最难场景, 比“两者通用互补”更贴合数据。

4. 六场景多方法收敛

图 3 将各方法在六个场景上的运行最优 J_b 收敛并列展示, 虚线标示 100 次公平预算。




图 3 六场景 × 多方法收敛对比（虚线：100 次预算；半透明带为 5 seed 间 ± 1 std）

图中三条信息值得留意。其一，预算对齐后各方法横轴统一止于 100，纵向可比；曲线为 5 seed 聚合的均值线加 ± 1 std 半透明带，带的宽窄直接反映稳定性——BF-SAC 的带最窄，SPSA、CMA-ES 在长春等场景明显发散。其二，BF-SAC 与 TPE 的下降都集中在前段，但 BF-SAC 越过 40 次竖线进入序贯段后仍能缓慢精炼，终点更低；CMA-ES 早期下降偏慢，呼应其样本饥渴的本性。其三，SPSA 在相同次数内始终位于上方，带越到后期越宽，说明预算耗尽时仍未收敛。

5. 综合讨论

核心机理：把预算花在刀刃上。 单次评估即需一次完整仿真，决定成败的不是用了多少次仿真，而是每一次花在何处。消融实验最有力地印证了这一点：总预算同为 100，纯 LHS 在所有场景都不如“40 次铺底 + 60 次 LCB 加点”。八维行为指纹先把崎岖的参数—误差关系压平到代理可学的程度，代理再把后半程的仿真定向投放到最有希望的区域——领域特征化与序贯决策的耦合，正是样本效率的来源。

框架对代理不敏感，RF 可作默认。 5 seed 后 RF 与 MLP 六场景平均几乎重合（0.241 与 0.240），逐场景看也大多落在彼此 ± 1 std 之内——真正可判定的差异只有 RML（MLP 0.408 对 RF 0.434）。这说明二者更像“同一机制下可互换的代理”，而非各占半壁的互补方法。其中仍有一条可解释的弱趋势：MLP 的高容量只在响应面崎岖、RF 拟合不足的难场景（RML、西安）兑现增益，易场景上则无差别甚至略逊。据此，RF 因轻量稳健宜作默认，MLP 在最难场景作备选；框架的价值恰在于不依赖某一种代理。

跨四种范式都领先，差距首先来自稳健性。 把基线扩到四个机制族后，结论更硬气：BF-SAC 在六场景平均上同时胜过 SPSA、GA、CMA-ES、TPE，优势不是与某类算法的偶然契合。其中 TPE 最接近（+6.7%），它同为模型类、收敛快，但逐维密度估计不如回归代理 + LCB 善用参数耦合；CMA-ES 在百次预算内还没“热身”够（+16.3%），暴露演化策略的样本饥渴；SPSA 因梯度失稳垫底。各基线性质不同——GA、CMA-ES 不至崩溃但收敛慢，SPSA 在崎岖场景直接失稳——但都败在同一处：把宝贵的仿真花在了盲目试探上。BF-SAC 的优势因而应理解为预算内的稳健最优，而非平均精度的微弱领先。

场景存在不可约的下界，评价需有节制。西安四法同处 0.43 附近、序贯几乎无增益，说明该场景误差主要源于指纹与参数空间的固有失配，已逼近当前建模能力的下界。这类场景的存在意味着标定质量的上限部分由问题本身决定；脱离场景难度谈绝对精度，容易高估或低估方法的真实贡献。

图表与数据文件。上述分析基于：`comparison_summary.csv`（180 行主对比：6 方法 × 6 场景 × 5 seed）、`comparison_multiseed_stats.csv`、`comparison_summary_sweep.csv` 及 `comparison_cache/`。本地重新作图：

```
python code/experiments/plot_all_figures.py
```

附录：复现流程

目标函数

每次评估 = 一次 `sumo` + `traci` 仿真； J_b 定义见第 1.2 节。

BF-SAC 标定

```
python code/calibration/unified_calibration.py
python code/calibration/unified_calibration.py XAM-N6
```

输出：`data/processed_data/calibration/{场景}_calibration.json`、`*_with_history.json`、`calibration_summary.csv`。

对比与消融

```
python code/experiments/run_comparison.py --mode main --scenes XAM-N6 --methods BF-SAC-RF,BF-SAC-MLP,SPSA,GA,CMA-ES,TPE
# 全场景 × 全方法 × 5 seed 并行补跑（CMA-ES 需 cma, TPE 需 optuna）
python code/experiments/run_batch_parallel.py --workers 12 --phases main
```

环境自检

```
python code/experiments/check_sumo_scenes.py
```

作图脚本

脚本	输出
<code>plot_all_figures.py</code>	三张 PNG + <code>ablation_summary.csv</code>
<code>plot_calibration_convergence.py</code>	<code>bfsac_calibration_convergence.png</code>
<code>plot_method_comparison.py</code>	<code>method_comparison_panel.png</code>

脚本	输出
plot_multiscene_convergence.py	multiscene_method_convergence.png
aggregate_multiseed.py / plot_multiseed_stats.py	comparison_multiseed_*.csv 、 multiseed_*.png